# Fair’ s Affairs

107354014 粘明揚

# 目錄
CONTENT


01 資料來源

02 資料解讀

03 資料分析

04 結論

# 第一部分

## 資料來源

# 資料來源

https://www.kaggle.com/clarkchong/fairs-affairs-dataset#Affairs.csv

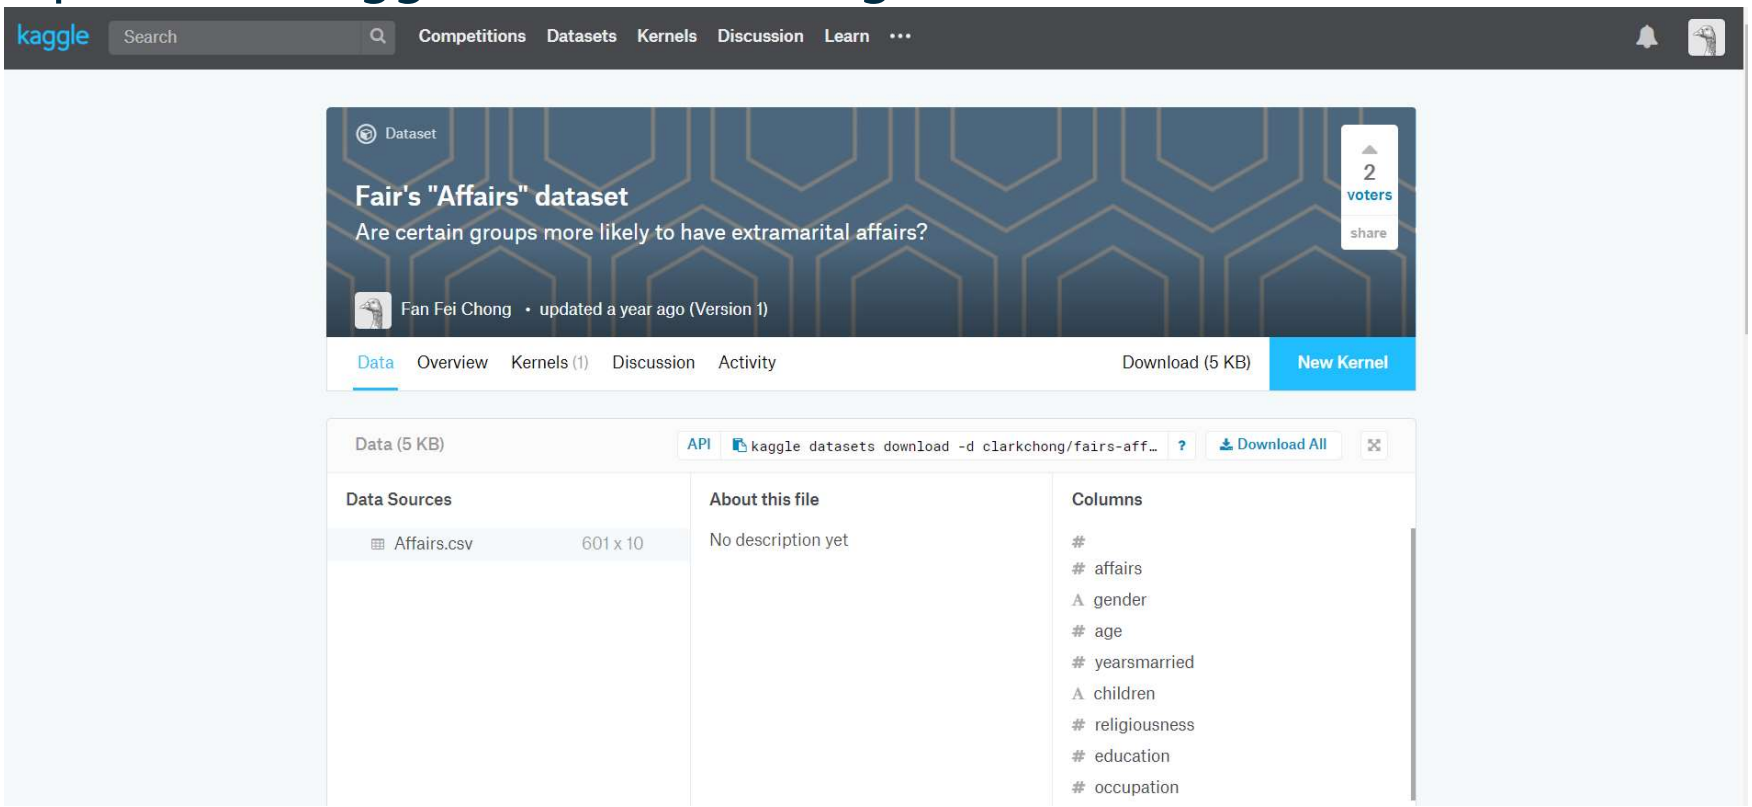

# 第二部分

資料解讀

# 資料解讀

## 定義描述

**出軌**

法律上，有性關係為出軌必要因素(雙方自願)
僅有思想或行為不貞，為精神出軌

# 資料解讀

## 數據描述

取自於1969年(Psychology Today)所做的一個調查

affairs
過去一年出軌次數

gender
性別(男=0女=1)

age
年齡

yearsmarried
結婚年數

children
是否有小孩(有=1無=0)

education
教育程度(20分滿分)

religiousness
宗教信仰程度(5分滿分)

occupation
職業種類

rating
婚姻滿意度(5分滿分)

# 資料解讀

## 將類別變數轉成數值型變數

```
table(Affairs$affairs)
Affairs$affairs[Affairs$affairs >= 1] <- 1
a <- sub("female",1,Affairs$gender)
b <- sub("male",0,a)
Affairs$gender <- a
Affairs$gender <-b
as.numeric(Affairs$gender)

table(Affairs$children)
c <- sub("yes",1,Affairs$children)
d<- sub("no",0,c)
Affairs$children <- c
Affairs$children<-d
Affairs$occupation <-as.factor(Affairs$occupation)
```

將出軌次數>0者令為1(有出軌)

女生令為0，男生令為1

有小孩令為1，無小孩令為0

令occupation中的數值為類別型(dummy variable)

# 第三部分

資料分析

# 資料分析

## 羅吉斯回歸

觀察模型及變數是否顯著

## 篩選重要變數

子集法:Stepwise Regression

## 配適模型好壞

ROC Curve

AUC

# 資料分析

## 羅吉斯回歸

### 羅吉斯回歸(尚未篩選變數)

有些變數對模型的貢獻並不顯著，於是想篩選變數，能否用簡單模型就可達到與原模型的表現與效果

```
Call:
glm(formula = affairs ~ ., data = train[, 2:10])

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-0.7588  -0.2870  -0.1517   0.4072   1.0468

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.726838   0.205164   3.543 0.000436 ***
gender1        0.014745   0.048659   0.303 0.762007
age           -0.006731   0.003435  -1.959 0.050667 .
yearsmarried   0.012804   0.006375   2.008 0.045167 *
children1      0.109777   0.054529   2.013 0.044670 *
religiousness -0.059472   0.016500  -3.604 0.000347 ***
education      0.005934   0.010297   0.576 0.564706
occupation2    0.167727   0.153641   1.092 0.275539
occupation3    0.085403   0.085153   1.003 0.316413
occupation4    0.144831   0.076974   1.882 0.060517 .
occupation5    0.003673   0.060927   0.060 0.951950
occupation6    0.072683   0.076470   0.950 0.342367
occupation7    0.174566   0.145908   1.196 0.232142
rating        -0.097584   0.018680  -5.224 2.64e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for gaussian family taken to be 0.1755021)

    Null deviance: 94.865  on 480  degrees of freedom
Residual deviance: 81.959  on 467  degrees of freedom
AIC: 543.82

Number of Fisher Scoring iterations: 2
```

# 資料分析

## 篩選重要變數

### Stepwise Regression

採用Stepwise Regression中的Backward Stepwise
在完整回歸中，逐一移除變數，直到移除任一變數，模型會損失過多解釋力時，則停止。
在Backward Stepwise中挑選的變數，為被留下的重要變數

```
#Backward Stepwise regression
# 1. 先建立一個完整的線性迴歸
full = glm(affairs ~ ., data = train[,2:10])

# 2. 用`step()`，一個一個把變數移除，看移除哪個變數後 AIC 下降最多
backward.glm = step(full,
                    scope = list(upper=full),
                    direction="backward")
summary(backward.glm)
```

```
Call:
glm(formula = affairs ~ age + yearsmarried + children + religiousness +
    rating, family = binomial(), data = train)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.7237  -0.7951  -0.5714   1.0059   2.4027

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)   1.92183    0.69562   2.763 0.005732 **
age          -0.03089    0.01889  -1.636 0.101899
yearsmarried  0.06081    0.03464   1.755 0.079180 .
children1     0.73318    0.32237   2.274 0.022946 *
religiousness -0.34394    0.09461  -3.635 0.000278 ***
rating        -0.50726    0.10077  -5.034 4.81e-07 ***
```

# 資料分析

配適模型好壞

```
95  #ROC Curve
96  install.packages("pROC")
97  library(pROC)
98
99  pre <- predict(fit.backward,Affairs)
100 modelroc <- roc(Affairs$affairs,pre)
101 plot(modelroc, print.auc=TRUE, auc.polygon=TRUE, grid=c(0.1, 0.2),
102      grid.col=c("green", "red"), max.auc.polygon=TRUE,
103      auc.polygon.col="skyblue", print.thres=TRUE)
```

**ROC Curve**
**AUC**

可以看到AUC值為0.71，表現還算尚可

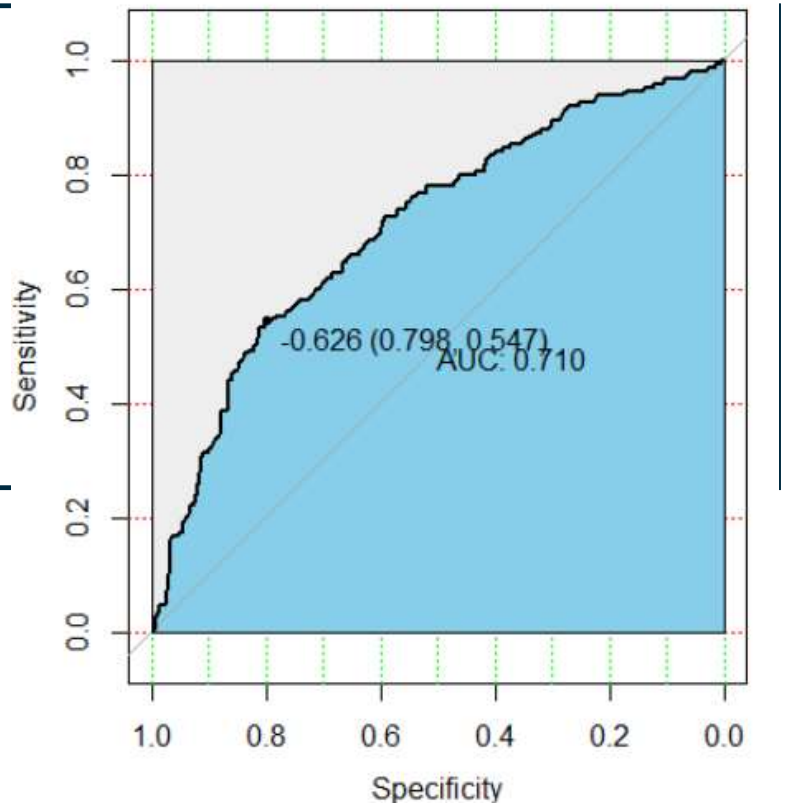

# 第四部分

結論

# 結論
## 模型解讀

```
93  coef(fit.backward)
94  #odds
95  exp(coef(fit.backward))
```

### 配適模型解讀

```
> coef(fit.backward)
  (Intercept)           age  yearsmarried     children1 religiousness        rating
   1.92182841   -0.03089141    0.06080538    0.73318263   -0.34393790   -0.50725840
> #odds
> exp(coef(fit.backward))
  (Intercept)           age  yearsmarried     children1 religiousness        rating
    6.8334414     0.9695809     1.0626921     2.0816953     0.7089730     0.6021442
```

在羅吉斯回歸中，迴歸係數的含義是當其他預測變量不變，一單位預測變量的變化可引起對數勝算比的變化，對其指數化即為勝算比的變化。例如:婚齡每增加一年，婚外情勝算比會乘以1.06

# 結論

## 模型預測

**模型預測**

```
107  test$prob <- predict(fit.backward,
108                       newdata=test,
109                       type="response")
110  test
```

| X | affairs | gender | age | yearsmarried | children | religiousness | education | occupation | rating | prob |
|---|---|---|---|---|---|---|---|---|---|---|
| 4 | 0 | 0 | 37.0 | 10.000 | 0 | 3 | 18 | 7 | 4 | 0.15789862 |
| 55 | 0 | 0 | 27.0 | 4.000 | 1 | 4 | 18 | 6 | 4 | 0.20740801 |
| 86 | 0 | 1 | 27.0 | 4.000 | 0 | 4 | 14 | 5 | 4 | 0.11166920 |
| 115 | 0 | 1 | 22.0 | 1.500 | 0 | 2 | 16 | 5 | 5 | 0.13115985 |
| 139 | 0 | 1 | 22.0 | 1.500 | 0 | 2 | 18 | 5 | 5 | 0.13115985 |
| 155 | 0 | 1 | 27.0 | 4.000 | 1 | 3 | 17 | 5 | 4 | 0.26959413 |
| 192 | 0 | 0 | 22.0 | 1.500 | 1 | 1 | 14 | 3 | 5 | 0.30711925 |
| 224 | 0 | 1 | 27.0 | 4.000 | 1 | 2 | 18 | 6 | 1 | 0.70454389 |
| 320 | 0 | 0 | 37.0 | 10.000 | 1 | 3 | 20 | 6 | 4 | 0.28074592 |
| 321 | 0 | 1 | 22.0 | 0.750 | 0 | 2 | 16 | 5 | 5 | 0.12604980 |
| 334 | 0 | 0 | 32.0 | 7.000 | 0 | 4 | 20 | 6 | 4 | 0.11447297 |
| 355 | 0 | 0 | 37.0 | 10.000 | 1 | 4 | 20 | 6 | 4 | 0.21675082 |
| 362 | 0 | 1 | 22.0 | 1.500 | 0 | 5 | 16 | 5 | 5 | 0.05104974 |

# 感謝觀看